

Actividad. Método supervisado en un análisis médico

Objetivos

El desarrollo de esta actividad tiene el objetivo de desarrollar un modelo supervisado basados en distancias sobre un conjunto de datos que permiten estudiar el concepto de fragilidad en adultos mayores.

Descripción

En medicina del envejecimiento se estudia el concepto de fragilidad, como un constructo que incluye las actividades básicas de la vida diaria, las actividades instrumentales de la vida diaria, el estado de salud, características psicológicas, etc. En general, se estudian un conjunto de variables binarias que indican la presencia o no de déficits.

La idea de esta Actividad es analizar datos correspondientes a una muestra longitudinal en un estudio de ancianos que abarca el año 2012 y 2015. Se tiene, entre otras muchas variables, la información de los déficits en 2012 y si el individuo muere o no entre el 2012 y 2015 a partir de la información del 2015.

1. Considera los datos (Base_deficit_y_muertos_112017_conesposos.dta) que incluye la muerte o no de los individuos entre el 2012 y 2015 (variable fallecido_15) a partir de un conjunto de 35 déficits. El objetivo es construir un clasificador tipo KNN para determinar si nuevos individuos en una ola del estudio estarán en más posibilidad de morir o no para la siguiente ola. Esto permite la posibilidad de implementar una intervención que disminuya ese riesgo. Puede ser conveniente seleccionar solo las variables que se van a estudiar. Esto puede hacerse por ejemplo

en R de la siguiente forma (la actividad puede resolverse en otro software como Python, así que esto es solo ilustrativo):

```
myvars2 <-c("h13_12_d_2", "h5_12_d_2", "h15d_12_d", "h17d_12_d",  
"h16d_12_d", "h19d_12_d", "h7_12_d_2", "h11_12_d_2", "h27c_12_d_2",  
"h26c_12_d_2", "h28c_12_d_2", "h29c_12_d_2", "c64_12_d", "c1_12_d",  
"c2a_12_d", "c73_12_d", "c49_8_12_d", "h3_12_d_2", "c49_2_12_d",  
"c49_1_12_d", "c49_4_12_d", "c49_5_12_d", "c49_9_12_d", "c4_12_d",  
"c22a_12_d", "c25b_12_d", "c26_12_d", "c12_12_menos10_d",  
"c6_12_d", "c32_12_d", "c19_12_d", "e1b_12_d", "c69a_12_d",  
"fallecido_15", "c70_12_d", "c50b_12_d")
```

```
newdata2 <- Base_esp[myvars2]
```

Y luego cambiar los nombres de las variables a cosas más indicativas de lo que son:

```
colnames(newdata2) <- c("Dress", "In_out_chair", "Walk", "Eat", "Groom",  
"Toilet", "Stairs", "Lift", "Shop", "Meals", "Meds", "Finance", "Lost_weight",  
"Health", "H_change", "Bed", "Tired", "Walk_out", "Effort", "Depressed",  
"No_Happy", "Lone", "No_Energy", "High_BP", "Heart_attack", "CHF",  
"Stroke", "Cancer", "Diabetes", "Arthritis", "CLD", "Memory", "Grip",  
"Dead", "Anorexia", "Exercise" )
```

De tal forma que las variables indican: dificultad (valor 1) o no (valor cero) para vestirse, levantarse de una silla, caminar, comer, arreglarse, ir al baño, levantar cosas pesadas, hacer las compras, cocinar sus alimentos, tomar sus medicamentos, manejar sus finanzas, así como pérdida de peso inexplicable, problemas de salud, cambios de salud, dificultad para levantarse de la cama, sentirse cansado, dificultad para caminar, sentir que todo es un esfuerzo, estar o no deprimido, ser infeliz, sentirse solo, sentirse sin energía, tener desde el último seguimiento presión arterial alta, ataque cardíaco, falla crónica del corazón, embolia, cáncer, diabetes, artritis, problemas pulmonares, fallas de memoria, dificultad para tomar objetos, si hay reporte de muerte entre el 2012 y 2015, tener anorexia y tener dificultad para ejercitarse. Posteriormente:

a Se considera que los datos perdidos corresponden a un esquema completamente al azar (MCAR) así que elimina todas aquellas observaciones con pérdidas en cualquiera de las variables.

b Dado que el número de individuos que mueren es bajo respecto a los que no, utiliza primero la precisión (recordar que este concepto es diferente a la exactitud o accuracy) como métrica para determinar la eficiencia del clasificador. Recuerda variar el valor de K hasta un valor óptimo, o sea que no haya sobreajuste, pero que a la vez se obtengan buenos valores en la métrica de interés.

c Repite el análisis utilizando la sensibilidad como métrica para determinar la eficiencia del clasificador y el valor óptimo de K.